



## ENCAJO N°4.

Es el algoritmo SOR, o determinante W.

Para ello debemos conocer:

Dado  $\tilde{x} \in \mathbb{R}^n$  aproximación a la solución de  $A\tilde{x} = b$

El vector residuo de  $\tilde{x}$  se define:

$$r = b - A\tilde{x} \quad \text{vector residual de } \tilde{x}$$

El objetivo del método es generar una sucesión de aproximaciones  $\{x^{(0)}, x^{(1)}, \dots, x^{(n)}, \dots\}$  que hacen que los vectores residuos converjan rápidamente a cero.

$r_j^{(k)} = \{r_1^{(k)}, r_2^{(k)}, \dots, r_n^{(k)}\}$ . Este es el vector residuo en la iteración  $(k)$  para en sistema  $Ax = b$  de  $n \times n$ .

La correspondiente vector solución será:

$$\tilde{x}^{(k)} = [x_1^{(k)}, x_2^{(k)}, \dots, x_{j-1}^{(k)}, x_j^{(k)}, \dots, x_n^{(k)}]^T$$

La  $m$ -ésima componente de  $\tilde{x}_j^{(k)}$

$$r_{mC}^{(k)} = b_m - \sum_{j=1}^{i-1} a_{mj} x_j^{(k)} - \sum_{j=i}^n a_{mj} x_j^{(k-1)} \quad \text{Gauss-Seidel}$$

es los  $x_j$  ya fueron calculados

la  $i$ -ésima componente del residuo cero:

$$r_{ii}^{(k)} = b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} - a_{ii} x_i^{(k-1)} \quad \text{separamos el término}$$

$$a_{ii} x_i^{(k-1)} + r_{ii}^{(k)} = b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)}$$

$$\Rightarrow a_{ii} x_i^{(k-1)} + r_{ii}^{(k)} = a_{ii} x_i^{(k)} \quad \rightarrow \text{del método de Gauss-Seidel.}$$



lo tanto para el método de Gauss - Seidel.

$$x_i^{(k)} = x_i^{(k-1)} + \frac{r_{ii}^{(k)}}{a_{ii}}$$

conexión entre los vectores residuales y el método de Gauss - Seidel.

$$r_{ii}^{(k)} \rightarrow \text{ocurrido a } x_{i+1}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_i^{(k)}, x_{i+1}^{(k-1)}, x_{i+2}^{(k-1)}, \dots, x_n^{(k)})$$

⇒ la  $i$ -esima componente será

$$r_{i,ii}^{(k)} = b_i - \sum_{j=1}^i a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)}$$

$$\Rightarrow r_{i,ii}^{(k)} = 0$$

$$r_{i,ii}^{(k)} = b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} - a_{ii} x_i^{(k)}$$

$$x_i^{(k)} = x_i^{(k-1)} + \omega \frac{r_{ii}^{(k)}}{a_{ii}}$$

De acuerdo como elegimos  $\omega$  punto es posible reducir la norma del vector residual y lograr una convergencia mucho más rápida.

↑ Si esto sucede todo esto se llama **MÉTODO DE RELAJACIÓN**.

Si  $0 < \omega < 1 \rightarrow$  SOBREAJACIÓN

$1 < \omega < 2 \rightarrow$  SOBREAJACIÓN

ocasiona la convergencia en métodos como Gauss - Seidel.  
SOR (Successive Over Relaxation)  
(sobrelajación sucesiva)

Reformulando la ecuación anterior

$$x_i^{(k)} = (1-\omega)x_i^{(k-1)} + \frac{\omega}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right]$$

Al igual que los otros los métodos determinan la matriz de iteración  $\Rightarrow$



$$x_i^{(k)} + w \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} = (1-w) x_i^{(k-1)} a_{ii} - w \sum_{j=i+1}^n a_{ij} x_j^{(k-1)}$$

⇒ en forma matricial vectorial zero:  $A = D - L - U$

$$(D - wL) x^k = [(1-w)D + wU] x^{k-1} + w b$$

$$x^{(k)} = \underbrace{(D - wL)^{-1} [(1-w)D + wU]}_{T_{SOR}} x^{(k-1)} + \underbrace{w(D - wL)^{-1} b}_{C_{SOR}}$$

Teoremas:

1) Si  $a_{ii} \neq 0$  para todo  $i = 1, 2, \dots, n \Rightarrow P(T_{SOR}) \geq |w - 1|$ .  
o sea el método sólo converge si  $0 < w < 2$ .

2) Si  $A$  es definida positiva y si  $0 < w < 2 \Rightarrow$   
SOR converge para cualquier vector inicial  $x^0 \in \mathbb{R}^n$ .

3) Si  $A$  es definito positivo y tri-diagonal  $\Rightarrow$  IMPORANTE  
 $P(T_{SOR}) = [P(T_J)]^2 < 1$  y la elección óptima de  $w$ .

$$w = \frac{2}{1 + \sqrt{1 - [P(T_J)]^2}}$$

con esta elección de  $w \rightarrow$  tenemos  $P(T_{SOR}) = w - 1$ .

Ejemplo:  $A = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix}$  simétrico, def positivo y tri-diagonal.

$$\Rightarrow T_J = D^{-1}(L+U) = \underbrace{\begin{bmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{bmatrix}}_{D^{-1}} \underbrace{\begin{bmatrix} 0 & -3 & 0 \\ -3 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}}_{L+U} = \underbrace{\begin{bmatrix} 0 & -0.75 & 0 \\ 0.75 & 0 & 0.25 \\ 0 & 0.25 & 0 \end{bmatrix}}_{T_J}$$



Tenemos dos autovalores  $\Rightarrow$

$$(\bar{J} - \lambda I) = \begin{bmatrix} -\lambda & -0.75 & 0 \\ -0.75 & -\lambda & 0.25 \\ 0 & 0.25 & -\lambda \end{bmatrix}$$

$$\det(\bar{J} - \lambda I) = -\lambda(\lambda^2 - 0.625)$$

Autovalores

$$\Rightarrow \lambda = 0 \quad \Rightarrow \text{como } \rho(\bar{J}) = \max_i |\lambda_i|$$
$$\lambda_1 = \pm \sqrt{0.625}$$

$$\Rightarrow \rho(\bar{J}) = \sqrt{0.625} \quad \text{por lo que } [\rho(\bar{J})]^2 = 0.625$$

$$\Rightarrow \omega_{op} = \frac{2}{1 + \sqrt{1 - (0.625)}} \approx 1.24 \quad \text{s } 1 < \omega < 2.$$

sobre relajación

y su convergencia será mucho más rápida

45) Dado la matriz:  $X^T A X > 0$  verifico

$$A = \begin{bmatrix} 10 & 5 & 0 & 0 \\ 5 & 10 & -4 & 0 \\ 0 & -4 & 8 & -1 \\ 0 & 0 & -1 & 5 \end{bmatrix}$$

triangular.  
simétrica def-positiva  
aplicamos SOR

$$b = [6 \ 25 \ -11 \ -11]^T$$

"para sacar el radio  
espectral en Octave (parte b)  
 $\rho = \max(\text{abs}(\text{eig}(A)))$ ;"

$$\Rightarrow \rho(T_{GS}) \leq [\rho(\bar{J})]^2 < 1.$$

$$\text{y } \omega = \frac{2}{1 + \sqrt{1 - [\rho(\bar{J})]^2}}$$

$$\rho(T_{GS}) = \omega - 1$$

$\Rightarrow$  Podemos usar eliminación Gaussiana y remos  
falso operando entre cambios de renglones -  
Res triangular con  $\rho = 3 \Rightarrow$  poseer triangular,  
simétrico, definido positivo  $\Rightarrow$  CONVERGE



selección de  $T_{\text{Jacobi}} \Rightarrow$

$$T_J = D^{-1}(L+U) = \underbrace{\begin{bmatrix} 1/10 & 0 & 0 \\ 0 & 1/10 & 0 \\ 0 & 0 & 1/5 \end{bmatrix}}_{D^{-1}} \cdot \underbrace{\begin{bmatrix} 0 & -5 & 0 & 0 \\ -5 & 0 & 4 & 0 \\ 0 & 4 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{L+U}$$

$$T_J = \begin{bmatrix} 0 & -1/2 & 0 & 0 \\ -1/2 & 0 & 2/5 & 0 \\ 0 & 1/2 & 0 & 1/8 \\ 0 & 0 & 1/5 & 0 \end{bmatrix} \Rightarrow |T_J - \lambda I| = ?$$

$$\det(T_J - \lambda I) = \det \begin{bmatrix} \lambda - 1/2 & 0 & 0 & 0 \\ -1/2 & \lambda & 2/5 & 0 \\ 0 & 1/2 & -\lambda & 1/8 \\ 0 & 0 & 1/5 & \lambda \end{bmatrix}$$

$$= -\lambda \begin{bmatrix} -\lambda & 2/5 & 0 \\ 1/2 & -\lambda & 1/8 \\ 0 & 1/5 & -\lambda \end{bmatrix} - (-1/2) \begin{bmatrix} 1/2 & 2/5 & 0 \\ 0 & -\lambda & 1/8 \\ 0 & 0 & 1/5 - \lambda \end{bmatrix} + 0 + 0$$

$$= -\lambda \left[ -\lambda^3 + \frac{\lambda}{40} + \frac{\lambda}{5} \right] + \frac{1}{2} \left[ -\frac{\lambda^3}{2} + \frac{1}{90} \right]$$

$$= \lambda^4 - \frac{9}{40} \lambda^2 - \frac{\lambda^2}{4} + \frac{1}{160} = \lambda^4 - \frac{19}{40} \lambda^2 + \frac{1}{160}$$

$$\boxed{\det(T_J - \lambda I) = 40 \lambda^4 - 19 \lambda^2 + \frac{1}{4} = 0}$$

$\text{As } t = \lambda^2 \Rightarrow$

$$40t^2 - 19t + \frac{1}{4} = 0$$

$$\Rightarrow \pm \sqrt{\frac{19 + \sqrt{321}}{80}} = \lambda_1, \lambda_2 \quad - \sqrt{\frac{19 - \sqrt{321}}{80}} < \lambda_3 < \lambda_4$$

Tomemos el máximo  $\lambda \Rightarrow$

$$\max |\lambda_k| = |\lambda_1| = |\lambda_2| \approx 0.6793 = P(T_J)$$

16 bits  $n=4$



l'mos calcular el optimo  $\Rightarrow$

$$\omega = \frac{2}{1 + \sqrt{1 - P(T_0)^2}} = \frac{2}{1 + \sqrt{1 - \frac{19+132}{80}}}.$$

$$\omega \approx \frac{8\sqrt{5}}{4\sqrt{5} + \sqrt{64+132}} \approx 1.0034$$

$$P(T_{0S}) = [P(T_0)]^2 = \frac{19+132}{80}$$

$$P(T_{0n}) = \omega - 1 = \frac{8\sqrt{5}}{1 + \sqrt{1 - \frac{19+132}{80}}} \approx 0.0034.$$

Si aplicamos los algoritmos de SOR y GS podemos ver q' ambos métodos llegan a la solución en 13 iteraciones con una tolerancia de  $10^{-4}$ .

Anto  $x_1 \approx -0.79761$ ,  $x_3 \approx -0.25884$

$x_2 \approx 2.79526$ ,  $x_4 \approx -2.25177$

Ambos convergen con el mismo numero se debe q' sea  $\omega \rightarrow 1$  y para este valor particular de  $\omega$ .

el método de SOR se convierte en el método de Gauss-Seidel.

Si SOR tiene el parámetro  $\omega = 1 \Rightarrow$  es Gauss-Seidel.

### NOTA

SOR: Se puede interpretar como un método PREDICOR CORRECTOR: Es decir el predictor puede ser un método como Jacobi o Gauss-Seidel, y el corrector realiza un promedio entre la iteración anterior y la obtenida por el PREDICOR (Jacobi o Gauss-Seidel)

— o —



Solucion de SOR a traves de JACOBI

$$\text{Jacobi} \quad x_i^{(k)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right] - \frac{a_{ii} x_i^{(k-1)}}{a_{ii} + a_{ii} x_i^{(k-1)}}$$

$$\Rightarrow x_i^{(k)} = x_i^{(k-1)} + \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^n a_{ij} x_j^{(k-1)} \right] \quad (1)$$

JACOBI.

SOR le aplico un coeficiente " $\omega$ " ob SOBRE RELAJACION.

$$x_{\text{SOR}}^{(k)} = \omega x_i^{(k-1)} + (1-\omega) x_i^{(k-1)}$$

obtenido de Jacobi (1)

$$x_{\text{SOR}}^{(k)} = (1-\omega) x_i^{(k-1)} + \frac{\omega}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k-1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right]$$

JACOBI

en forma matricial

$$A = L + D + U \Rightarrow$$

$$D \underline{x}_{\text{SOR}}^{(k)} = (1-\omega) D \underline{x}^{(k-1)} + \omega \left[ \underline{b} - (L+U) \underline{x}^{(k-1)} \right]$$

E decir  $\underline{x}_{\text{SOR}}^{(k)} = \underline{T}_{\text{SOR}} \underline{x}^{(k-1)} + \underline{c}_{\text{SOR}}$

$$\Rightarrow \underline{x}^{(k)} = (1-\omega) \underline{x}^{(k-1)} + \omega D^{-1} \underline{b} - \omega D^{-1} (L+U) \underline{x}^{(k-1)}$$

$$\underline{x}^{(k)} = \underbrace{[(1-\omega) - \omega D^{-1} (L+U)]}_{T_{\text{SOR}}} \underline{x}^{(k-1)} + \underbrace{\omega D^{-1} \underline{b}}_{c_{\text{SOR}}}$$



obtenido a través de GAUSS- SEIDEL

$$\xrightarrow{GS} \underline{x}_i^{(k)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right] + a_{ii} x_i^{(k-1)} - a_{ii} x_i^{(k-1)}$$

Le sumamos y restamos.

$$\xrightarrow{GS} \underline{x}_i^{(k)} = \underline{x}_i^{(k-1)} + \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right] \quad (2)$$

eliminando el factor de sobrerelajación "ω"

$$\underline{x}_i^{(k)} = \omega \underline{x}_i^{(k)} + (1-\omega) \underline{x}_i^{(k-1)} \quad \text{anterior}$$

Actual (iteración  $(k)$ ) reemplazo por (2)

$$x_{i,SOR}^{(k)} = (1-\omega) \underline{x}_i^{(k-1)} + \frac{\omega}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right]$$

factorizamos o descomponemos la matriz A en

$$A = L + D + U.$$

$$D \underline{x}_{i,SOR}^{(k)} = (1-\omega) D \underline{x}^{(k-1)} + \omega [b - L \underline{x}^{(k)} - U \underline{x}^{(k-1)}]$$

que es:

$$\Rightarrow (D + \omega L) \underline{x}_{i,SOR}^{(k)} = (1-\omega) D \underline{x}^{(k-1)} + \omega [b - U \underline{x}^{(k-1)}].$$

$$(D + \omega L) \underline{x}_{i,SOR}^{(k)} = [(1-\omega) D - \omega U] \underline{x}^{(k-1)} + \omega b.$$

$$x_{i,SOR}^{(k)} = \frac{(D + \omega L)^{-1} [(1-\omega) D - \omega U] \underline{x}^{(k-1)} + \frac{(D + \omega L)^{-1} \omega b}{C_{SOR}}}{T_{SOR}}$$



hubieramos hecho lo siguiente:

$$[A = D - L - U] \Rightarrow$$

$$x_{\text{sol}}^{(k)} = \{(D - \omega L)^{-1}[(I - \omega)D + \omega U]\} x^{(k-1)} + \omega (D - \omega L)^{-1} b$$

¿Cómo formamos la ecuación del error?

$$(D + \omega L) e^{(k)} = [(1 - \omega)D - \omega U] e^{(k-1)}$$

e: error

promedio entre los errores de la iteración actual y la anterior. multiplicamos ambos miembros por  $D^{-1}$

$$(I + \omega D^{-1}L) e^{(k)} = [(1 - \omega)I - \omega D^{-1}U] e^{(k-1)}$$

$$e^{(k)} = (I + \omega D^{-1}L)^{-1} [(1 - \omega)I - \omega D^{-1}U] e^{(k-1)}$$

$$\|e^{(k)}\| \leq \|(I + \omega D^{-1}L)^{-1}\| \|[(1 - \omega)I - \omega D^{-1}U]\| \|e^{(k-1)}\|.$$

$$(I + \omega D^{-1}L)^{-1} [(1 - \omega)I - \omega D^{-1}U].$$

Porque minimizar el error hay que minimizar la norma de este matriz.

En el caso de (sol) la convergencia del método es lineal. Y luego de "m" iteraciones el error está controlado por:

$$\|x - x^{(k)}\| \leq C^m \|x - x^{(0)}\|.$$

Si se requiere una tolerancia de errores relativo  $\epsilon$ .  
⇒ el nro de iteraciones debe ser:

$$m \geq \frac{\ln \epsilon}{\ln C}$$

$$\frac{\|x - x^{(k)}\|}{\|x - x^{(0)}\|} \leq C^m.$$

$$\Rightarrow \ln \epsilon \leq m \ln C.$$